

多くの問題設定ではアルゴリズムやモデルの準備以上に訓練データの用意が重要です。例えば画像の分類問題では、訓練データとなる画像すべてにアノテーションをつける作業（正解となる入出力の組を用意する作業）が必要で、基本的には人手作業です。教師なし学習は訓練データすべてにラベルが付いていない状態で学習できますが、得られたクラスタの意味づけには人間の判断が必要です。訓練データに使いたいデータの一部にはラベルがついている（かつ、ラベルのないデータは入手が容易）という状況も多く、さまざまな半教師あり学習手法が提案されています。

強化学習は、ある環境内におけるエージェントが、現在の状態を観測し、将来の期待報酬を最大化するような行動を学習するという問題設定です。正解となる訓練データは与えられず、試行錯誤を通じて学習が行われます。強化学習はロボットの制御や自動運転などの基礎となる機械学習手法で、AlphaGoのアルゴリズムとしても近年注目を集めました⁶⁸⁾。

表 4.3 さまざまな教師あり学習タスク

タスク	入 力	出 力
スパムフィルタ	メール	ラベル
一般物体認識	写真	ものの種類・位置
超解像	低解像度の画像	高解像度の画像
音声認識	音声データ	文字列
機械翻訳	英文	和文
物性予測	化学式	機能・性質

教師あり学習は $f(\mathbf{x}) \simeq y$ となる f の推定（近似）と理解できますが、計算機では f の候補をパラメータで指定される関数やネットワーク構造に限定し、パラメータの最適化問題として解きます。よく使われるのは

$$f_{\mathbf{w}}(\mathbf{x}) = \sum_{j=1}^N w_j \phi_j(\mathbf{x})$$

のようにパラメータ w_j と基底関数 ϕ_j で書かれる線形モデルです。基底関数は、多項式や三角多項式などが使われます。カーネルモデルは訓練データ $\mathbf{x}_i$ を使い

$$f_{\mathbf{w}}(\mathbf{x}) = \sum_{i=1}^N w_i K(\mathbf{x}, \mathbf{x}_i)$$

と表されます。カーネルモデルのパラメータ数 N は入力データの次元 d には依存

しません（訓練データ数に依存します）。ガウシアンカーネル（＝ガウス関数）

$$K(\mathbf{x}, \mathbf{c}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{c}\|^2}{2h^2}\right)$$

がよく利用されます。このようにカーネル関数そのものが線形である必要はありませんが、 $f_{\mathbf{w}}(\mathbf{x})$ はパラメータ $\mathbf{w}$ に対して線形です。 $\mathbf{x}$ を非線形変換する関数そのものを陽に計算することなしにその内積に相当するカーネルの計算のみで識別を行うテクニックはカーネルトリックと呼ばれます。最適なパラメータ $\mathbf{w}$ はある制約条件の下での2次計画問題（の双対問題）を解くことで得られます^{63, 64)}。

ニューラルネットワークや決定木など、関数以外のモデルもよく利用されます。多くの層とパラメータを使うニューラルネットワークを使う学習モデルは深層学習とも呼ばれます。決定木モデルは樹形構造で段階的にデータを分割する手法で、前処理の少なさと解釈の容易さから人気があります。

機械学習における“学習”はパラメータの最適化を意味しますが、その際に最小化すべき目的関数（コスト関数）は主に損失関数と正則化項からなります。損失関数はモデル予測と訓練データとの差を評価する関数で、平均2乗誤差、ヒンジ損失関数、クロスエントロピー誤差関数など適切なものを選ぶ必要があります。

また、訓練データのみについての最適化（＝経験損失の最小化）をしてしまうと、本番の入力に対して精度の良い予測ができなくなります（過学習）。そこで、損失関数（経験損失）と正則化項 $\lambda \Omega(\mathbf{w})$ の和の最小化でこの誤差（汎化誤差）を小さくします（ $\mathbf{w}$ はパラメータ、 λ はハイパーパラメータ）。この処理は正則化と呼ばれ、さまざまな方法があります（表 4.4）。

問題設定とモデル以外に、各種の計算コストについても注意を払う必要があります。機械学習で頻出する計算は各種の線形代数演算で、逆行列やヘッセ行列の

表 4.4 さまざまな正則化

正則化法	正則化項	効 果
L2 正則化	$\ \mathbf{w}\ _2^2$	$\mathbf{w}$ の大きさを抑える効果がある。最もよく使われる正則化法。線形回帰モデルのリッジ回帰、ニューラルネットワークモデルの荷重減衰と等価。
L1 正則化	$\ \mathbf{w}\ _1$	いくつかのパラメータを0にし、特徴量の選択を行う効果がある。線形回帰モデルでの LASSO 回帰。
L0 正則化	$\ \mathbf{w}\ _0$	0 でないパラメータの数を制限する。どのパラメータを採用するかは一般には組合せ最適化問題となり、計算コストは大きい。