

ポイントは、古典コンピュータでは A の固有ベクトル $\{\mathbf{u}_i\}$ を知らなければ $\mathbf{b} = \sum_i \beta_i \mathbf{u}_i$ と展開できないところを、量子コンピュータ上では振幅エンコーディングで $|b\rangle$ さえ用意すれば、 $|b\rangle = \sum_i \beta_i |u_i\rangle$ のように展開された状態について計算できることです。 $\{\mathbf{u}_i\}$ を基底にすると A は対角行列で、逆行列演算 $A^{-1}\mathbf{b}$ も単に λ_i の割り算なので、解 $\mathbf{x}$ は $\mathbf{x} = A^{-1}\mathbf{b} = \sum_i \frac{\beta_i}{\lambda_i} \mathbf{u}_i$ と求まります。

まず、量子位相推定サブルーチンにより、初期状態 $|b\rangle$ に制御 e^{iA} ゲートを作用させ、レジスタ量子ビット $|0\rangle_r$ に

$$|0\rangle_r \sum_i \left(\beta_i |u_i\rangle \right) |0\rangle_a \xrightarrow{\text{QPE}} \sum_i \left(\beta_i |\lambda_i\rangle_r |u_i\rangle \right) |0\rangle_a$$

のように固有値 λ_i を取り出します。次に、 $|\lambda_i\rangle_r$ を制御部とする制御回転ゲート操作を別途用意した補助量子ビット $|0\rangle_a$ に作用させ、 $1/\lambda_i$ を計算します（この手順は2.7.2項と同様の方法です）。これにより

$$|\lambda_i\rangle_r |0\rangle_a \xrightarrow{\text{Ctrl-}R_y} |\lambda_i\rangle_r \left(\frac{1}{\lambda_i} |0\rangle_a + \sqrt{1 - \frac{1}{\lambda_i^2}} |1\rangle_a \right)$$

という状態を作れます。最後に補助量子ビットを測定し0が出たときには

$$\sum_i \beta_i |\lambda_i\rangle_r |u_i\rangle \left(\frac{1}{\lambda_i} |0\rangle_a + \sqrt{1 - \frac{1}{\lambda_i^2}} |1\rangle_a \right) \rightarrow C \sum_i \frac{\beta_i}{\lambda_i} |\lambda_i\rangle_r |u_i\rangle |0\rangle_a$$

という状態になっています（ C は規格化定数）。最後に位相推定サブルーチンの逆変換を行い、 $|\lambda_i\rangle_r$ を

$$C \sum_i \frac{\beta_i}{\lambda_i} |\lambda_i\rangle_r |u_i\rangle |0\rangle_a \xrightarrow{\text{QPE}^{-1}} C |0\rangle_r \left(\sum_i \frac{\beta_i}{\lambda_i} |u_i\rangle \right) |0\rangle_a$$

と初期状態に戻します。これで、 $A^{-1}\mathbf{b}$ という状態が得られました。

エンコーディングの観点で見ると、振幅エンコーディングで用意した $|b\rangle$ を使った量子位相推定サブルーチンによって、固有値 λ_i はまず基底エンコーディングで $|\lambda_i\rangle_r$ とレジスタ量子ビットに入ります。そして、量子版算術演算、制御 R_y ゲート操作、補助量子ビットの測定を経ると、（確率的に）振幅エンコーディングされた $\lambda_i^{-1} |\lambda_i\rangle_r$ が得られる、という流れになっています²⁰⁾。

古典アルゴリズムによる線形方程式の解法のベストは計算量 $O(Ns\kappa \log(1/\epsilon))$ の共役勾配法です⁷²⁾。行列 A がスパース ($s \sim O(\text{poly log } N)$) なら、HHL アルゴリズムは行列 A の次元 N について指数加速していることになりす^{19, 71)}。

4.4.3 ささまざまな量子機械学習アルゴリズム

量子コンピュータで機械学習を行うアルゴリズム（量子機械学習アルゴリズム）を、これまでに紹介した量子アルゴリズムとともに表4.5にまとめました^{19, 73, 74)}。主な戦略は、最適化問題として定式化してグローバーの検索アルゴリズム（4.3節）を用いるか、逆行列演算に帰着してHHLアルゴリズムを用いるかです。以降の節ではHHLアルゴリズムを基本とする教師あり機械学習アルゴリズムとして量子線形回帰と量子サポートベクタマシン、教師なし機械学習アルゴリズムとして量子主成分分析を紹介します。

表4.5 本書で紹介する量子アルゴリズム

アルゴリズム	サブルーチン	量子加速	データ	節番号
ショアの素因数分解アルゴリズム ⁷⁵⁾	位相推定	指数	古典	4.1
量子化学計算 (Full-CI 計算) ⁷⁶⁾	位相推定	指数	古典	4.2
グローバーの検索アルゴリズム ⁷⁷⁾	振幅増幅	2次	量子	4.3
線形方程式 (HHL アルゴリズム) ⁷¹⁾	位相推定	指数	量子	4.4
(教師あり機械学習)				
線形回帰 (行列はスパース) ⁷⁸⁾	HHL	指数	量子	-
線形回帰 (行列は低ランク近似可能) ⁷⁹⁾	HHL	指数	量子	4.4.4
k 近傍法 ⁸⁰⁾	G	2次	古典	-
サポートベクタマシン ⁸¹⁾	G	2次	古典	-
サポートベクタマシン ⁸²⁾	HHL	指数	量子	4.4.5
(教師なし機械学習)				
主成分分析 ³³⁾	HHL	指数	量子	-
主成分分析 ²⁷⁾	HHL+QW	指数	量子	4.4.6
クラスタリング (K-means) ⁸³⁾	G	指数	量子	-
クラスタリング (K-median) ⁸⁴⁾	G	2次	古典	-
階層的クラスタリング ⁸⁴⁾	G	2次	古典	-
(強化学習)				
Q学習 ⁸⁵⁾	G	2次	古典	-
Projective Simulation ^{86, 87)}	G, QW	2次	古典	-

(G: グローバーの検索アルゴリズム, QW: 量子ウォーク)