

4.4.4 量子線形回帰

線形回帰は M 次元の実数ベクトルの教師データ $\mathbf{x}$ が N 個与えられたときに

$$f_{\mathbf{w}}(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x}$$

の形の線形モデルを用いて $\mathbf{x}$ と出力 $\mathbf{y}$ の関係 $\mathbf{y} = f_{\mathbf{w}}(\mathbf{x})$ を学習する機械学習手法です (ただし, データ $\mathbf{x} = \{\mathbf{x}_i\}_{i=0}^M$ の先頭には $x_0 = 1$ が入っており, オフセットパラメータ w_0 がパラメータベクトル $\mathbf{w}$ の先頭に入っているとします). N 個のデータベクトル $\mathbf{x}^{(j)}$ からなる行列 $X := [\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(N)}]^T$ (行列の (i, j) 成分は $x_j^{(i)}$) を使うと, 損失関数 (2乗誤差) を最小化する問題は

$$\frac{\partial}{\partial \mathbf{w}} \|\mathbf{y} - X\mathbf{w}\|^2 = \frac{\partial}{\partial \mathbf{w}} (\mathbf{y} - X\mathbf{w})^T (\mathbf{y} - X\mathbf{w}) = -2X^T (\mathbf{y} - X\mathbf{w}) = 0$$

より

$$X^T X \mathbf{w} = X^T \mathbf{y}$$

という方程式に帰着されます. したがって, 最適なパラメータ $\mathbf{w}^*$ は

$$\mathbf{w}^* = (X^T X)^{-1} X^T \mathbf{y}$$

で計算できます. $(X^T X)^{-1} X^T$ は X の疑似逆行列と呼ばれ, 行列 X が

$$X = U \text{diag}(\sigma_1 \cdots \sigma_M) V^T$$

のように特異値分解により低ランク近似できると仮定すると

$$(X^T X)^{-1} X^T = V \text{diag}\left(\frac{1}{\sigma_1}, \dots, \frac{1}{\sigma_r}, 0, \dots, 0\right) U^T \quad (4.9)$$

と書けます (r 個の非ゼロの特異値は大きさの降順に並んでいるとします).

未知のデータ $\tilde{\mathbf{x}}$ に対する予測は, 学習済みのモデル $f_{\mathbf{w}^*}(\mathbf{x})$ に $\tilde{\mathbf{x}}$ を入力し

$$\begin{aligned} f_{\mathbf{w}^*}(\tilde{\mathbf{x}}) &= \sum_i w_i^* \tilde{x}_i \\ &= \sum_{i=1}^r \frac{1}{\sigma_i} \left(\sum_{j=1}^M v_{ji} \tilde{x}_j \right) \left(\sum_{k=1}^N u_{ik} y_k \right) \end{aligned} \quad (4.10)$$

によって計算できます. ここで, v_{ij}, u_{ij} は行列 V, U の i, j 成分を表します.

量子コンピュータで線形回帰を行う量子アルゴリズムはウィーブラによって提案されたアルゴリズム⁷⁸⁾があります. この提案方法は HHL アルゴリズムによる $X^T X$ の逆行列計算がベースとなっていますが, 量子位相推定サブルーチンの効率的な実行のために行列 $X^T X$ のスパース性を仮定しています. これは後述するように, $e^{iX^T X t}$ が量子コンピュータ上で効率的に実行できるかどうかに関係しています. 本項では, この部分に密度行列冪 (3.7 節) を使うことでスパースでない行列にも適用できるシュルドらのアルゴリズム⁷⁹⁾を紹介します. ただし, こちらもスパースでない場合にいつでも使えるということではなく, $X^T X$ を低ランク近似できることが仮定されています. 基本的な流れは以下のように HHL アルゴリズムに似ています.

(学習)

- i) 補助量子ビット $|+\rangle_a$ を用意し, $|0\rangle_a$ のときに以下の操作を行う.
- ii) $\frac{1}{\sqrt{N}} \sum_{i=1}^N |x_i\rangle |i\rangle$ を用意する.
- iii) 行列 $X^T X$ を密度行列 $\rho_X = \sum_{i,j} (X^T X)_{ij} |i\rangle \langle j|$ にエンコードする.
- iv) $\frac{1}{\sqrt{N}} \sum_{i=1}^N |x_i\rangle |i\rangle$ に対して制御 $e^{-i\rho_X t}$ ゲートを使った位相推定サブルーチンを実行し, $X^T X$ の固有値 σ_i^2 を補助量子ビットに書き込む. $e^{-i\rho_X t}$ ゲートは密度行列冪によって SWAP ゲートで近似する.
- v) 制御回転ゲートと補助量子ビットの測定 (2.7.2 項と同様) により $\frac{1}{\sigma_i^2}$ を掛け $\sum_{i=1}^r \frac{1}{\sigma_i} |v_i\rangle |u_i\rangle$ を得る. 逆演算 (uncomputation) で不要な量子ビットを $|0\rangle$ に戻す (ここで, $\mathbf{v}_i = \{v_{ji}\}_{j=1}^M, \mathbf{u}_i = \{u_{ji}\}_{j=1}^N$).
- vi) $|\psi_1\rangle = \frac{1}{\sqrt{\sum_k \sigma_k^{-2}}} \sum_{k=1}^r \frac{1}{\sigma_k} |v_k\rangle |u_k\rangle$ を得る.

(予測)

- i) 補助量子ビットが $|1\rangle_a$ のときに, 未知入力データ $\tilde{\mathbf{x}}$ と訓練出力 $\mathbf{y}$ をエンコードした $|\psi_2\rangle = |\tilde{\mathbf{x}}\rangle |\mathbf{y}\rangle = \sum_{i=1}^N \tilde{x}_i |i\rangle \sum_{j=1}^M y_j |j\rangle$ を用意する.
- ii) $\frac{1}{\sqrt{2}} (|0\rangle_a |\psi_1\rangle + |1\rangle_a |\psi_2\rangle)$ を準備し, 補助量子ビットにアダマールゲートを作用させてから測定する.
- iii) 測定結果が 0 となる期待値から内積 $\langle \psi_1 | \psi_2 \rangle = f_{\mathbf{w}^*}(\tilde{\mathbf{x}})$ が得られる.