

4.4.6 量子主成分分析

主成分分析は、ある行列 X の低ランクの行列での近似で、特異値分解とも呼ばれます。機械学習では、データ行列 X を特異値分解することで考慮すべき特徴量を絞り（次元削減）、訓練データの説明にあまり寄与しない（特異値の小さい）部分を捨てる前処理としてよく利用されます。精度にもよりますが、古典アルゴリズムの計算量は $N \times M$ 行列に対して $O(NM^2)$ ($N \geq M$) 程度です。

N 個の M 次元データを表す $N \times M$ 行列 X を特異値分解すると

$$X = USV_{\text{SVD}}^T$$

$$= \begin{bmatrix} u_{11} & \cdots & \cdots & u_{1N} \\ \vdots & & & \vdots \\ \vdots & & & \vdots \\ u_{N1} & \cdots & \cdots & u_{NN} \end{bmatrix} \begin{bmatrix} \sigma_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sigma_M \\ 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix} \begin{bmatrix} v_{11} & \cdots & v_{1M} \\ \vdots & \ddots & \vdots \\ v_{M1} & \cdots & v_{MM} \end{bmatrix}$$

と書けるので、あるしきい値 σ_{th} よりも大きな特異値 σ_i にかかる行と列のみを取り出すことで X を近似できます。

このことは、主成分分析として考えると、共分散行列 Σ の固有値分解 (λ_i は大きい順に並べた i 番目の固有値、対応する M 次元の固有ベクトルを $\mathbf{v}_i$ とします)

$$\Sigma = \frac{X^T X}{N-1}$$

$$= V_{\text{PCA}} L V_{\text{PCA}}^T$$

$$= \begin{bmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_M \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & & \ddots & \vdots \\ 0 & \cdots & \cdots & \lambda_M \end{bmatrix} \begin{bmatrix} \mathbf{v}_1 \\ \mathbf{v}_2 \\ \vdots \\ \mathbf{v}_M \end{bmatrix}$$

について V_{PCA} から第 k 主成分 $\mathbf{v}_k$ までをとってきて M 次元から k 次元に特徴量の次元を削減することに対応します。 $M \times M$ 行列 $S^T S$ の固有値は σ_i^2 ですから、 $X^T X$ の固有値は X の特異値と $\lambda_i = \sigma_i^2$ の関係になっています。

この処理を量子コンピュータによって行うには、シンプルには HHL アルゴリズムによって $X^T X$ の固有値を求めることが考えられます。実際、密度行列冪を

用いて $e^{i\rho t}$ を実行することで $X^T X$ の固有値を取り出すアルゴリズムが提案されています³³⁾。この方法は精度 ε に対して $O(1/\varepsilon^3)$ の計算量ですが、本節で紹介する $O(1/\varepsilon)$ の巧妙なアルゴリズムが後に提案されました^{23, 27)}。

このアルゴリズムは、量子ウォークというユニタリ行列 W を、その固有値 θ が $X^T X$ の固有値 (X の特異値) に対応するよう上手に構築し、量子位相推定サブルーチンで固有値を取り出すことで実現します (量子ウォークについては後述します^{*20)}。アルゴリズムの全体の流れは以下のとおりです。量子回路で書くと図 4.12 のようになります。

- i) データ $\mathbf{x}_i$ から $|a_i\rangle := |x_i\rangle |i\rangle$ と $|b_j\rangle := |j\rangle \frac{1}{\sqrt{N}} \sum_{i=1}^N |i\rangle$ を用意する ($|x_i\rangle$ は M 次元ベクトル、 $|i\rangle$ は N 次元ベクトルなので $|a_i\rangle$ は MN 次元ベクトル)。
- ii) 量子ウォーク $W := \left(2 \sum_{i=1}^N |a_i\rangle \langle a_i| - I\right) \left(2 \sum_{j=1}^M |b_j\rangle \langle b_j| - I\right)$ を構築する。
- iii) $\frac{1}{\sqrt{N}} \sum_{i=1}^N |x_i\rangle |i\rangle$ に対して e^{iW} を使った量子位相推定サブルーチンを実行し $\sum_{k=1}^r |\mu_{k,\pm}\rangle |\sigma_k^2\rangle$ を得る ($|\mu_{k,\pm}\rangle$ は W の固有ベクトル)。
- iv) 補助量子ビットを追加し、 $\sigma_k > \sigma_{\text{th}}$ を条件とする CNOT ゲート (のような操作) を行う。
- v) 補助ビットを測定し $|0\rangle$ が出れば $\sum_{k=1}^{k_{\text{th}}} |\mu_{k,\pm}\rangle |\sigma_k^2\rangle |0\rangle$ が得られる ($\sigma_k > \sigma_{\text{th}}$ 部分のみを取り出す)。
- vi) 量子位相推定サブルーチンまで含めて逆演算 (uncomputation) して余計な量子ビットを初期状態に戻すと $\frac{1}{\sqrt{N}} \sum_{i=1}^N |x_{\text{th},i}\rangle |i\rangle$ が得られる ($\mathbf{x}_{\text{th},i}$ は次元削減後 X_{th} の行ベクトル)。

量子ウォーク W とは、 N 個の正規直交ベクトル $\{|a_i\rangle\}_{i=1}^N$ と、 M 個の正規直交ベクトル $\{|b_j\rangle\}_{j=1}^M$ を使って

$$W = \left(2 \sum_{i=1}^N |a_i\rangle \langle a_i| - I\right) \left(2 \sum_{j=1}^M |b_j\rangle \langle b_j| - I\right)$$

と定義される演算子です。実は、前に紹介した振幅増幅サブルーチン (3.5 節) は

*20 量子ウォークを用いて固有値を求める手法は文献 88) も参考にしてください。